

Análise e Mitigação da Centralização de Caminhos em Sistemas de Recomendação Baseados em Grafos Temporais

Lucas de Lima Guarnieri

April 2026

1 Links

Repositório com código-fonte (tratamento dos dados, geração dos grafos e análises iniciais):

<https://github.com/lucas-guarnieri/mc859-project>

Repositório com os grafos gerados:

<https://github.com/lucas-guarnieri/mc859-project/releases/tag/graphs-v1>

- Link alternativo para download:

https://drive.google.com/drive/folders/10dyR_Y3LfG_0ylmkjpWywazlkgwQGzp?usp=drive_link

2 Introdução

Sistemas de recomendação, atualmente amplamente utilizados em plataformas digitais para sugerir produtos e conteúdos com base no histórico de interação dos usuários, podem sofrer, ao longo do tempo, uma redução na diversidade das recomendações oferecidas. Isso ocorre, em grande parte, devido a um fenômeno que pode ser interpretado como uma centralização de caminhos no grafo usuário–produto utilizado para gerar as sugestões.

Ao longo do tempo, produtos muito populares tendem a se tornar nós altamente conectados no grafo, concentrando uma parcela significativa dos caminhos utilizados na geração de recomendações. Como consequência, algoritmos podem passar a favorecer repetidamente determinados produtos ou categorias, prejudicando a variedade das sugestões apresentadas aos usuários.

O objetivo deste projeto é estudar a centralização de caminhos em sistemas de recomendação, bem como analisar e propor estratégias para a mitigação desse fenômeno. Busca-se, assim, encontrar soluções que permitam gerar recomendações mais variadas, mantendo ao mesmo tempo um elevado grau de relevância para os usuários.

3 Base de Dados e Pré-processamento

A base de dados utilizada nesse projeto foi o Amazon Reviews Dataset. Além do volume substancial de dados, a base fornece nota atribuída e timestamp para cada uma das interações usuário–produto, permitindo o recorte temporal e uma métrica extra além da popularidade para avaliar a relevância das recomendações geradas. A base usa identificadores anônimos de usuários, eliminando problemas relativos a privacidade.

Dada a disponibilidade limitada de recursos computacionais, a primeira etapa do pré-processamento consistiu na seleção de um recorte da base de dados original. O subconjunto escolhido corresponde às reviews de produtos da categoria de eletrônicos a partir do ano de 2010, considerando apenas produtos com ao menos cinco reviews recebidas e usuários com ao menos cinco reviews realizadas.

A categoria de eletrônicos representa aproximadamente 10% do volume total de reviews do dataset, ainda mantendo uma quantidade expressiva de interações para a realização do estudo. A restrição temporal a partir de 2010 teve como objetivo reduzir o custo computacional sem comprometer a qualidade da análise, uma vez que o volume de dados cresce de forma mais acentuada a partir desse período, acompanhando a

expansão da plataforma Amazon. Por fim, o filtro mínimo de cinco interações por usuário e por produto, além de contribuir para a redução do volume processado, concentra a análise em usuários e itens mais representativos, reduzindo ruídos associados a interações esparsas e permitindo uma investigação estrutural mais consistente.

Na segunda etapa do pré-processamento, os dados foram organizados em snapshots temporais anuais. Cada snapshot representa o conjunto acumulado de interações observadas até o final de um determinado ano, permitindo analisar a evolução estrutural da rede ao longo do tempo. Adicionalmente, com o objetivo de reduzir o consumo de recursos computacionais, os identificadores textuais de usuários e produtos foram convertidos para valores numéricos em um espaço global único de identificadores. Esse procedimento garante consistência entre os diferentes recortes temporais e evita colisões entre os dois tipos de vértices.

A partir dos dados obtidos após essa etapa, foi construído, para os snapshots de 2016, 2017 e 2018, um grafo bipartido não direcionado no qual os vértices representam duas entidades distintas: usuários e produtos. As arestas conectam um usuário a um produto sempre que existe uma avaliação registrada entre eles.

Além da estrutura de conectividade, cada aresta armazena atributos associados à interação original, incluindo a nota atribuída pelo usuário ao produto (*rating*) e o instante temporal da avaliação (*timestamp*). Essa modelagem preserva informações relevantes para análises posteriores, como filtragens temporais, ponderações por avaliação e estudos evolutivos.

Após a construção, cada grafo foi exportado no formato GraphML, escolhido por sua ampla compatibilidade com bibliotecas de análise de redes e ferramentas de visualização. Dessa forma, cada ano considerado passa a possuir uma instância própria de grafo, possibilitando a comparação de métricas estruturais entre diferentes períodos.

4 Análise Inicial dos Grafos

Para a coleta inicial de métricas, foi utilizado o grafo `graph_2018.graphml`, que corresponde ao snapshot temporal do ano de 2018, o último ano da série de dados disponível. Devido à característica acumulativa dos snapshots, esse grafo agrega todas as interações observadas a partir de 2010, representando, portanto, a visão mais completa da rede utilizada neste projeto.

Em relação às métricas estruturais de tamanho, o grafo possui 1.038.656 vértices e 6.738.816 arestas, o que implica um grau médio de aproximadamente 12,976. A seguir, é apresentada a distribuição dos graus dos vértices no grafo completo:




Figure 1: Distribuição dos graus no grafo completo (2018).

Entretanto, as métricas obtidas considerando o grafo global são menos informativas quando se leva em conta

que a estrutura é composta por diferentes tipos de vértices, os quais apresentam comportamentos estruturais distintos. Nesse sentido, a análise segmentada entre usuários e produtos fornece uma visão mais adequada da rede.

Considerando apenas os vértices do tipo usuário, observa-se um total de 773.044 nós, com grau médio de 8,717. Já os vértices correspondentes a produtos totalizam 265.612 nós, apresentando um grau médio significativamente maior, de 25,371.

As distribuições de grau para os vértices de usuários e produtos são apresentadas a seguir:




Figure 2: Distribuição dos graus dos vértices do tipo usuário.




Figure 3: Distribuição dos graus dos vértices do tipo produto.

As distribuições de grau observadas para o grafo completo, bem como para os subconjuntos de usuários e produtos, apresentam comportamento de cauda longa (heavy-tailed). Isso indica que a maioria dos vértices possui grau baixo, enquanto uma pequena fração concentra um número desproporcionalmente alto de conexões. No caso dos vértices de usuários, observa-se que a maioria interage com poucos produtos, enquanto um

número reduzido de usuários altamente ativos interage com uma grande quantidade de itens. Para os vértices de produtos, essa concentração é ainda mais acentuada: a maior parte dos produtos recebe poucas interações, enquanto um subconjunto reduzido atinge graus muito elevados. Essa assimetria estrutural indica uma forte concentração de popularidade nos nós de produto, o que é particularmente relevante para sistemas de recomendação, uma vez que itens de alto grau podem dominar métodos baseados em caminhadas na rede ou em vizinhança, influenciando significativamente as recomendações geradas.

Nesta análise inicial também foi explorada a quantidade de componentes no grafo. O grafo apresenta um total de 12 componentes distintas, sendo que a componente principal possui tamanho 1.038.631, enquanto a menor componente contém apenas 2 vértices.

É interessante notar dois aspectos principais. O primeiro é que apenas 25 vértices estão fora da componente principal, o que corresponde a aproximadamente 0,002% do total de vértices, indicando que quase todos os nós pertencem à mesma estrutura conectada dominante. O segundo aspecto é a existência de componentes com menos de 10 vértices, o que não era esperado dado o critério de filtragem aplicado inicialmente, no qual foram removidos usuários com menos de 5 reviews e produtos com menos de 5 reviews recebidas.

O primeiro fato pode ser explicado pela própria natureza da filtragem aplicada: ao restringir o conjunto de dados a usuários mais ativos e produtos mais populares, é esperado que essas entidades formem uma estrutura altamente conectada, resultando em um grafo praticamente conectado em sua totalidade.

Já o segundo fato está relacionado à forma como as interações são representadas. Como o grafo é binário, múltiplas interações entre um mesmo usuário e produto são condensadas em uma única aresta. Dessa forma, ainda que um usuário ou produto atenda ao critério mínimo de interações, a estrutura final pode gerar pequenas componentes isoladas dependendo de como essas conexões se distribuem.

Diante disso, as análises subsequentes serão realizadas considerando apenas a componente principal do grafo.

A seguir, apresenta-se a distribuição do tamanho das componentes do grafo:




Figure 4: Distribuição do tamanho das componentes do grafo