

UNIVERSIDADE ESTADUAL DE CAMPINAS
Instituto de Computação

MC859 – Projeto em Teoria da Computação

Análise e Mitigação da Centralização de Caminhos em Sistemas de Recomendação Baseados em Grafos Temporais

Lucas de Lima Guarnieri
RA 119756

Projeto apresentado à disciplina **MC859**, ministrada no Instituto de
Computação da Universidade Estadual de Campinas.

Campinas – SP
2026

Sumário

1	Introdução	2
2	Metodologia	2
2.1	Tratamento e preparação de dados	2
2.2	Geração de recomendações	3
2.3	Métricas de avaliação	6
3	Resultados	8
3.1	Precisão e Relevância	8
3.2	Diversidade e Cobertura	8
3.3	Centralização Estrutural	9
3.4	Degradação Temporal	9
4	Conclusão	10
	Links	14
	Referências	15

1 Introdução

Em plataformas digitais, a recomendação de produtos e conteúdos é uma prática amplamente adotada — de marketplaces como Amazon e Mercado Livre a serviços de streaming como Netflix e Spotify. Uma estratégia consolidada para esse fim é representar as interações entre usuários e produtos por meio de grafos, nos quais usuários e produtos são modelados como nós e suas interações como arestas. Essa representação permite explorar relações indiretas, denominadas *multi-hop*, nas quais recomendações são inferidas a partir de caminhos que atravessam múltiplos nós intermediários — ampliando a capacidade do sistema de capturar padrões complexos. Entretanto, ao longo do tempo, produtos altamente populares tornam-se nós extremamente conectados, concentrando grande parte dos caminhos de inferência. Esse fenômeno, denominado centralização de caminhos (*path centralization*), reduz a diversidade estrutural dos caminhos utilizados pelo sistema e introduz um viés de popularidade que prejudica o alcance de itens menos conhecidos — um efeito nocivo tanto para usuários quanto para produtores de conteúdo.

O objetivo deste projeto é analisar esse fenômeno por meio de um estudo experimental comparativo e avaliar estratégias de mitigação contra seus efeitos. Para isso, utiliza-se o Amazon Reviews Dataset [4], base amplamente empregada na literatura, com mais de 15 anos de registros de avaliações de produtos, organizada por data, categoria e nota, e com identificadores anônimos de usuários. O estudo envolve a representação dos dados em grafo, a implementação de modelos de recomendação — incluindo abordagens clássicas, métodos baseados em caminhos e variantes com Personalized PageRank — e a avaliação temporal dos modelos, na qual o treinamento é realizado com dados de um período e a avaliação com interações do período seguinte. Com isso, espera-se construir uma base comparativa suficiente para verificar se os modelos propostos melhoram a diversidade das recomendações sem comprometer sua relevância. O link para o repositório contendo o código-fonte deste projeto bem como os links para os grafos gerados e analisados encontram-se na seção de Links.

2 Metodologia

2.1 Tratamento e preparação de dados

O dataset fornece tabelas em formato CSV contendo avaliações, metadados de produtos e links associados. Após inspeção inicial, constatou-se nível adequado de integridade, não

sendo necessárias etapas adicionais de limpeza. Dadas as limitações computacionais do ambiente disponível, o estudo foi restrito às reviews da categoria de eletrônicos a partir de 2010, considerando apenas produtos e usuários com ao menos cinco interações registradas. Essa categoria representa aproximadamente 10% do volume total do dataset, mantendo uma quantidade expressiva de interações. A restrição temporal concentra o estudo no período de crescimento mais acentuado da plataforma, e o filtro mínimo de cinco interações reduz ruídos associados a interações esparsas, além de contribuir para a redução do volume processado.

Os dados filtrados foram organizados em snapshots temporais anuais, cada um representando o conjunto acumulado de interações até o final do respectivo ano. Os identificadores textuais de usuários e produtos foram convertidos para valores numéricos em um espaço global único, garantindo consistência entre os diferentes recortes temporais e evitando colisões entre os dois tipos de vértices.

A partir desses snapshots, foram construídos grafos bipartidos não direcionados para os anos de 2015, 2016, 2017 e 2018, nos quais usuários e produtos são modelados como vértices e suas interações como arestas. Cada aresta armazena a nota atribuída (*rating*) e o instante temporal da avaliação (*timestamp*), preservando informações relevantes para filtragens e ponderações posteriores. Os grafos foram exportados no formato GraphML, escolhido por sua ampla compatibilidade com bibliotecas de análise de redes, de modo que cada ano possui uma instância própria, permitindo a comparação de métricas estruturais entre períodos.

2.2 Geração de recomendações

A geração de recomendações nesse projeto foi realizada de forma separada para três snapshots: 2015, 2016 e 2017. Para cada período de tempo, ao todo, foram usados oito modelos de recomendação que se dividem em três categorias: modelos de referência (baseline), modelos baseados em caminhos no grafo e PageRank personalizado.

Enquanto os modelos baseados em caminhos de grafo são o objeto de estudo desse projeto, os modelos de referência servem como limite inferior de desempenho dado que exploram as relações de maneira bastante simples e direta. Para qualquer modelo de recomendação se justificar, seu desempenho deve ser superior aos dessa categoria. Já o PageRank personalizado é uma referência de modelo de recomendação baseado em grafo bem consolidada, servindo de parâmetro de comparação mais refinado para os modelos propostos nesse estudo.

Modelos de Referência

1 - Popularidade Global

Esse modelo serve como o limite inferior de desempenho: recomenda os k produtos com maior número de interações no grafo de treino, descartando os itens já avaliados pelo usuário. O score de cada produto é o seu grau no grafo, nesse caso o número de vezes que o produto foi avaliado. Não usa nenhuma informação sobre o perfil individual do usuário.

2 - Co-ocorrência com Similaridade de Jaccard

Dois produtos co-ocorrem quando ao menos um usuário interagiu com ambos. A força dessa relação é medida pelo coeficiente de Jaccard entre os conjuntos de usuários de cada

produto:

$$Jaccard(p_1, p_2) = \frac{|U(p_1) \cap U(p_2)|}{|U(p_1) \cup U(p_2)|}$$

onde $U(p)$ é o conjunto de usuários que avaliaram o produto p .

Para gerar recomendações a um usuário, o modelo agrega os scores de Jaccard entre os itens já vistos pelo usuário e os candidatos:

$$score(p_{candidato}) = \sum_{p_{visto} \in H_u} Jaccard(p_{visto}, p_{candidato})$$

Retorna os k candidatos com maior score acumulado. Um índice invertido (produto $\rightarrow$ lista de pares co-ocorrentes) foi construído durante o ajuste do modelo para evitar varredura do catálogo completo a cada recomendação.

3 - Filtragem Colaborativa por Item (Item-CF)

Nesse método [1] foi construída uma matriz de interações M (produtos $\times$ usuários) onde $M[i,j]$ é a nota dada pelo usuário j ao produto i . A similaridade entre produtos é calculada pelo cosseno entre seus vetores de avaliação, após normalização L2:

$$sim(p_1, p_2) = \mathbf{M}_{norm}[p_1] \cdot \mathbf{M}_{norm}[p_2]$$

onde M_{norm} é a matriz M com cada linha dividida por sua norma.

Para cada produto, apenas os top- N vizinhos mais similares foram armazenados ($N=50$). As recomendações são geradas pela soma ponderada dos scores de similaridade, usando as notas do próprio usuário como pesos:

$$score(p_{candidato}) = \sum_{p_{visto} \in H_u} sim(p_{visto}, p_{candidato}) \cdot rating(p_{visto})$$

Modelos Baseados em Caminho no Grafo

Os modelos que constituem a base de estudo deste projeto geram recomendações a partir da exploração da estrutura do grafo bipartido usuários/produtos [5]. Dado um valor fixo x , o modelo percorre caminhos de comprimento x a partir do usuário-alvo. Por limitações computacionais, este projeto explorou apenas caminhos de comprimento 3 (3-hop), que seguem a seguinte sequência:

$$\text{usuário} \rightarrow \text{produto_avaliado} \rightarrow \text{usuário_similar} \rightarrow \text{produto_candidato}$$

Cada passo do caminho atravessa uma aresta do grafo. A ideia central é que produtos acessíveis por caminhos curtos e bem conectados a partir do histórico do usuário têm maior probabilidade de serem relevantes.

1 - Multi-Hop (sem penalização)

O modelo Multi-Hop tradicional define o *score* de um produto candidato à recomendação como a soma dos pesos de todos os caminhos de comprimento 3 que partem do usuário-alvo e chegam até ele. O peso de cada caminho é inversamente proporcional ao grau dos nós intermediários:

$$\text{peso}(\text{user} \rightarrow p_1 \rightarrow u_2 \rightarrow p_2) = \frac{1}{\text{grau}(p_1)} \times \frac{1}{\text{grau}(u_2)}$$

Essa ponderação reduz a contribuição de nós genéricos (com muitas conexões) e amplifica caminhos que passam por nós mais específicos. O Algoritmo 1 descreve o pseudocódigo para esse modelo.

2 - Multi-Hop Penalizado

Esta variação do modelo Multi-Hop foi proposta dado o objetivo deste projeto em mitigar os efeitos da concentração de caminhos ao longo de grandes períodos. Aqui, o peso de cada nó intermediário é calculado por uma função de penalização $\text{pen}(\cdot)$ aplicada ao seu grau, em vez de simplesmente $1/\text{grau}$. Dessa forma, espera-se reduzir mais agressivamente a influência de *hubs* — produtos muito populares que concentram caminhos e introduzem viés de popularidade nas recomendações.

Três funções de penalização foram avaliadas:

$$\text{pen_sqrt}(d) = \frac{1}{\sqrt{d}} \quad (\text{penalização suave}) \quad (2.1)$$

$$\text{pen_log}(d) = \frac{1}{\ln(1+d)} \quad (\text{penalização moderada}) \quad (2.2)$$

$$\text{pen_quadratic}(d) = \frac{1}{d^2} \quad (\text{penalização severa}) \quad (2.3)$$

A escolha da função determina com que intensidade nós de alto grau são penalizados: pen_sqrt reduz pouco a influência de *hubs*, pen_log reduz moderadamente, e pen_quadratic praticamente os elimina. O Algoritmo 2 descreve o pseudocódigo para esse modelo, válido para qualquer função de penalização.

A diferença em relação ao modelo Multi-Hop tradicional reside exclusivamente no cálculo de w_1 e w_2 : no modelo sem penalização, o peso é $1/\text{grau}$; no modelo penalizado, é $\text{pen}(\text{grau})$, onde pen pode amplificar ou atenuar a penalização de nós de diferentes graus.

Pagerank Personalizado (PPR)

O Personalized PageRank (PPR) [3] adapta o algoritmo PageRank clássico para gerar um vetor de *scores* centrado em um nó de origem específico — no caso, o usuário-alvo. O *score* de cada nó representa a probabilidade de um caminhante aleatório, que parte do usuário e ocasionalmente retorna a ele, estar naquele nó em um dado instante.

A fórmula iterativa é:

$$\pi \leftarrow \alpha \times A_{\text{norm}} \times \pi + (1 - \alpha) \times e_u$$

onde:

- π : vetor de *scores* sobre todos os nós do grafo;
- A_{norm} : matriz de adjacência normalizada por coluna, com $A_{\text{norm}}[j, i] = 1/\text{grau}(i)$;
- e_u : vetor de personalização — valor 1 no nó do usuário-alvo e 0 nos demais;
- α : fator de amortecimento (*damping factor*), fixado em 0,85.

A iteração converge quando a variação entre dois passos consecutivos é inferior a um limiar $\|\pi_{t+1} - \pi_t\|_1 < 10^{-6}$, com limite máximo de 100 iterações. Para recomendar ao usuário u , os produtos candidatos são ordenados pelo *score* π correspondente ao seu nó no grafo, excluindo itens já avaliados.

Pré-cômputo em lote (*batch* PPR). Calcular o PPR individualmente para cada usuário — executando a iteração de potências uma vez por usuário — é computacionalmente ineficiente. Em vez disso, os *scores* de múltiplos usuários são calculados simultaneamente por meio de multiplicação de matrizes esparsas, conforme descrito no Algoritmo 3. Ao processar os usuários em blocos de 100, o pico de memória é limitado a $\mathcal{O}(|V| \times 100)$, independentemente do total de usuários avaliados.

2.3 Métricas de avaliação

Pipeline de Avaliação Temporal

A avaliação segue um protocolo temporal: cada modelo é treinado sobre as interações do ano T e avaliado sobre as interações novas observadas no ano $T + 1$, nos três períodos a seguir:

$$2015 \rightarrow 2016, \quad 2016 \rightarrow 2017, \quad 2017 \rightarrow 2018$$

O conjunto de teste de cada usuário contém apenas interações genuinamente novas — presentes no grafo de $T + 1$ e ausentes no de T . Para viabilidade computacional, 1000 usuários são amostrados aleatoriamente por período, com semente fixa (*seed*=42). Dois modos de avaliação foram utilizados: **all**, em que toda nova interação é considerada relevante, e **rated**, em que apenas interações com nota $\geq 4,0$ são consideradas relevantes, aproximando a avaliação de um cenário de satisfação do usuário.

Métricas de Relevância

As métricas abaixo são calculadas por usuário e agregadas pela média, com lista de recomendação de tamanho fixo $K = 10$.

Precision@K mede a fração dos K itens recomendados que são relevantes:

$$\text{Precision@K} = \frac{|\text{recomendados} \cap \text{relevantes}|}{K}$$

Recall@K mede a fração dos itens relevantes recuperados entre os K recomendados:

$$\text{Recall@K} = \frac{|\text{recomendados} \cap \text{relevantes}|}{|\text{relevantes}|}$$

Precision e Recall são métricas complementares [1]: a primeira penaliza recomendações incorretas, enquanto a segunda penaliza itens relevantes não recuperados.

NDCG@K avalia a qualidade do ranqueamento, penalizando itens relevantes em posições inferiores da lista:

$$\text{NDCG@K} = \frac{\text{DCG@K}}{\text{IDCG@K}}, \quad \text{DCG@K} = \sum_{i=1}^K \frac{\text{rel}_i}{\log_2(i+1)}$$

onde $\text{rel}_i = 1$ se o item na posição i é relevante e 0 caso contrário, e IDCG é o valor máximo possível de DCG [2]. Essa métrica foi incluída por capturar não apenas quais itens foram acertados, mas em que posição aparecem na lista.

Métricas de Qualidade das Listas

Diversidade mede o quão distantes dos itens mais populares são os produtos recomendados, onde a popularidade de um item é seu grau no grafo de treino:

$$\text{diversity} = 1 - \frac{\text{popularidade média dos itens recomendados}}{\text{popularidade máxima no catálogo}}$$

Cobertura (*Coverage*) mede a fração do catálogo total que aparece em ao menos uma lista de recomendação entre todos os usuários avaliados. Modelos com baixa cobertura tendem a recomendar repetidamente o mesmo subconjunto de produtos.

Coeficiente de Gini de Recomendação mede a desigualdade na distribuição de frequência com que cada produto aparece nas listas de recomendação. Complementa a cobertura: enquanto esta indica o alcance do modelo sobre o catálogo, o Gini captura a intensidade da concentração naquilo que é recomendado.

Métricas de Centralização de Caminhos

Calculadas exclusivamente para os modelos baseados em caminhos no grafo (`multi_hop` e `multi_hop_penalized`), essas métricas quantificam em que medida os nós intermediários dos caminhos de recomendação estão concentrados em produtos populares (*hubs*).

Entropia dos Caminhos mede a dispersão do uso dos nós intermediários, tratando sua frequência de uso como uma distribuição de probabilidade:

$$H = - \sum_i p_i \log_2(p_i), \quad p_i = \frac{\text{usos}(i)}{\text{total de usos}}$$

Serve como medida de referência: valores altos indicam caminhos bem distribuídos; valores baixos indicam concentração.

Coeficiente de Gini dos Nós Intermediários aplica o mesmo coeficiente de Gini sobre a distribuição de uso dos nós intermediários. É especialmente sensível ao extremo superior da distribuição, tornando-o mais informativo que a entropia para detectar a presença de poucos nós com uso muito acima da média.

Concentração em Hubs mede a fração do total de usos de caminhos que passa por nós cujo grau supera o percentil 90 da distribuição de graus dos produtos:

$$\text{Hub_concentration} = \frac{\text{usos em nós hub}}{\text{total de usos}}$$

É a métrica mais diretamente ligada à hipótese do estudo, respondendo objetivamente à pergunta: que fração dos caminhos ainda passa por produtos muito populares, mesmo com penalização?

Correlação Grau–Uso é a correlação de Pearson entre o grau de cada nó produto e o número de vezes que aparece como intermediário nos caminhos. Diferentemente das métricas anteriores, ela relaciona o uso dos nós à sua posição estrutural no grafo, permitindo distinguir se a concentração em hubs é uma consequência da topologia da rede ou do viés

algorítmico do modelo.

3 Resultados

3.1 Precisão e Relevância

A Figura 4.1a apresenta a Precision@10 de todos os oito modelos avaliados nos três períodos temporais e nos dois modos de avaliação. O padrão é consistente entre os cenários: os modelos multi-hop penalizados lideram em precisão em todos os casos, com superioridade clara em relação aos baselines clássicos e ao modelo de referência de grafo.

No modo **all** — em que qualquer nova interação no período de teste é considerada relevante — o multi-hop penalizado com raiz quadrada (`sqrt`) alcança os maiores valores de Precision@10 nos três períodos: 0,0026 (2015→2016), 0,0022 (2016→2017) e 0,0013 (2017→2018). Para efeito de comparação, o melhor baseline clássico (popularidade global) atinge no máximo 0,0014 no período 2015→2016. O modelo Item-CF, apesar de ser o mais sofisticado entre os baselines, apresenta os menores valores de precisão do conjunto — entre 0,0001 e 0,0005 — resultado consistente com a esparsidade da matriz de co-interações no dataset de eletrônicos.

No modo **rated** — em que apenas interações com avaliação $\geq 4,0$ são consideradas relevantes — o perfil de liderança se altera: o multi-hop penalizado com função logarítmica (`log`) assume vantagem consistente, atingindo Precision@10 de 0,0028 (2015→2016) e NDCG@10 de 0,0060 (2017→2018). Esse padrão sugere que a penalização logarítmica, mais seletiva que a raiz quadrada em graus moderados, produz um conjunto de candidatos mais alinhado a produtos de alta qualidade percebida pelo usuário. A distinção entre os dois modos indica que `sqrt` e `log` não são equivalentes: o primeiro é superior quando o critério de relevância é amplo; o segundo quando é mais restritivo, aproximando-se de uma noção de satisfação real do usuário. O modelo `quadratic` apresenta desempenho consistentemente inferior ao das demais variantes multi-hop em todos os períodos e modos — a penalização por $1/d^2$ elimina de forma excessiva caminhos informativos, restringindo os candidatos a produtos pouco conectados e com menor sinal histórico.

O PageRank personalizado posiciona-se entre os baselines clássicos e os modelos propostos, competindo com o multi-hop não penalizado em vários cenários, mas sem alcançar os valores das variantes com penalização. Isso indica que a estrutura de caminho explícito com ponderação de grau já oferece um ganho sobre o mecanismo de passeio aleatório implícito do PageRank, e que a penalização potencializa esse ganho de forma significativa.

3.2 Diversidade e Cobertura

A Figura 4.1b situa cada modelo em um espaço de precisão média e diversidade média sobre os seis cenários avaliados, evidenciando o *trade-off* estrutural entre as duas dimensões: modelos de maior precisão tendem a apresentar menor diversidade.

Os modelos Item-CF e co-ocorrência ocupam o extremo de alta diversidade (aproximadamente 0,94 e 0,90, respectivamente) com baixa precisão. Esse padrão indica que a alta diversidade nesses modelos é, em grande medida, reflexo da ausência de um sinal claro de preferência: sem critério seletivo, as listas de recomendação se tornam mais distribuídas sobre o catálogo, mas com menor acerto. Os modelos *sqrt* e *log* ocupam o extremo oposto, com maior precisão ($\approx 0,002$) e menor diversidade ($\approx 0,72$). Ao favorecer caminhos mais curtos e específicos, esses modelos concentram as recomendações em um subconjunto compacto do catálogo — cobrindo menos de 1,6% dos produtos, em contraste com os 3,5%–4,5% cobertos por co-ocorrência e Item-CF. Um caso particular é o modelo de popularidade, que apresenta baixa diversidade sem, contudo, alcançar precisão proporcional: por ser não personalizado, todos os usuários recebem a mesma lista de produtos populares, o que explica tanto a baixa diversidade quanto o desempenho intermediário.

3.3 Centralização Estrutural

As métricas de centralização revelam um viés estrutural persistente na forma como o grafo direciona os caminhos de recomendação. Essas métricas foram calculadas sobre a variante não penalizada (*multi_hop_3*), que serve de representante da estrutura de caminhos compartilhada por todos os modelos multi-hop, dado que a penalização altera os pesos mas não os caminhos percorridos. A concentração em hubs atingiu 0,824 no período 2015→2016 e 0,827 no período 2016→2017, indicando que mais de 82% de todos os caminhos percorridos transitam por produtos cujo grau supera o percentil 90 da distribuição. O coeficiente de Gini dos nós intermediários confirma essa concentração: 0,872 e 0,874, respectivamente. A correlação de Pearson entre grau do nó e uso em caminhos ficou em torno de 0,80 nos dois períodos, sugerindo que a conectividade estrutural dos hubs explica uma parcela substancial da variância no seu uso como intermediários.

Esses valores são estáveis entre os períodos avaliados, evidenciando que o padrão não é um artefato temporal, mas uma propriedade da topologia do grafo. A implicação direta é que mesmo as variantes penalizadas não conseguem escapar significativamente desse viés: em um grafo bipartido esparsos com distribuição de graus *heavy-tailed*, caminhos de comprimento 3 inevitavelmente transitam por hubs, pois esses são os únicos nós com conectividade suficiente para propagar o sinal entre usuários distintos.

3.4 Degradação Temporal

A análise temporal, ilustrada na Figura 4.1a pela progressão de desempenho entre os três períodos, mostra que todos os modelos apresentam queda sistemática de precisão ao longo do tempo, sem exceção. Os valores de *Precision@10* do melhor modelo (*sqrt*, modo *all*) caem de 0,0026 no período 2015→2016 para 0,0013 no período 2017→2018 — uma redução de aproximadamente 50%. O crescimento do grafo oferece uma hipótese explicativa: o total de usos de caminhos aumentou de 44,5 milhões (2015→2016) para 82,0 milhões (2016→2017) — dado disponível para os dois primeiros períodos —, e à medida que a densidade cresce, o sinal de cada trajetória individual se dilui entre um número crescente de caminhos concorrentes. A uniformidade da degradação entre todos os modelos, nos três

períodos, é consistente com uma causa estrutural, não com o viés de um modelo específico.

4 Conclusão

Este trabalho investigou o uso de grafos bipartidos como estrutura central para recomendação de produtos, com foco na análise do viés de popularidade introduzido por modelos baseados em exploração de caminhos. Os resultados obtidos em três períodos temporais e oito modelos confirmam que os modelos multi-hop penalizados superam consistentemente os baselines clássicos e o PageRank personalizado em precisão, validando a hipótese central do projeto de que a exploração estruturada de caminhos com ponderação de grau captura padrões de co-consumo mais informativos do que abordagens de co-ocorrência simples ou passeio aleatório.

A escolha da função de penalização tem impacto direto no perfil de recomendação. A penalização por raiz quadrada ($\sqrt{\cdot}$) é a mais equilibrada para o critério de relevância amplo, produzindo maior precisão geral sem eliminar caminhos informativos. A penalização logarítmica ($\log$) é superior quando o critério de relevância é restrito a interações de alta qualidade, sendo o único modelo consistentemente mais forte nesse cenário em todos os períodos avaliados. A penalização quadrática mostrou-se excessivamente restritiva em todos os cenários, indicando que eliminar de forma severa a influência dos hubs prejudica a cobertura de candidatos relevantes.

Apesar dos ganhos em precisão, os modelos propostos apresentam um *trade-off* claro com diversidade: recomendações mais precisas são obtidas à custa de menor cobertura do catálogo e maior concentração das listas, conforme evidenciado na Figura 4.1b. Esse comportamento é uma propriedade inerente à abordagem de caminho explícito com ponderação de popularidade — quanto mais seletiva a ponderação, mais as recomendações convergem para um subconjunto específico do catálogo.

O viés estrutural de popularidade, quantificado pelas métricas de centralização, é o achado mais robusto do estudo. A concentração em hubs acima de 0,82 e a correlação grau-uso de aproximadamente 0,80 indicam que, mesmo com penalização, mais de 80% dos caminhos transitam por produtos de alto grau — padrão estável entre os períodos avaliados. A implicação prática é que nenhuma função de penalização aplicada internamente ao processo de percurso dos caminhos é suficiente para eliminar o viés de popularidade em grafos bipartidos esparsos com distribuição de graus *heavy-tailed*. A mitigação efetiva desse viés exigiria intervenção direta na estrutura do grafo ou mecanismos de diversificação em pós-processamento.

A degradação temporal de desempenho observada uniformemente em todos os modelos reforça que a densidade crescente do grafo é um fator limitante independente da escolha de modelo. Estratégias que funcionam bem em redes esparsas podem requerer ajustes de parâmetros ou janelas temporais mais curtas para manter desempenho adequado à medida que o grafo cresce.

Como direções de trabalho futuro, os resultados apontam para três frentes principais: a

incorporação de nós de categoria ao grafo bipartido, que poderia diversificar os tipos de intermediário disponíveis nos caminhos e reduzir o viés de popularidade de forma estrutural; mecanismos de diversificação em pós-processamento das listas, como o re-ranqueamento por diversidade máxima marginal (MMR), para recuperar cobertura sem sacrificar a qualidade dos candidatos gerados; e a avaliação com janelas temporais mais curtas ou esquemas de decaimento temporal das interações, para atenuar o efeito do crescimento do grafo na degradação de desempenho observada entre os períodos analisados.

Algoritmos e Figuras

Algorithm 1: Multi-Hop Tradicional

Require: grafo G , usuário $user$, conjunto K
Ensure: lista dos K produtos com maior $score$

- 1: $seen \leftarrow$ produtos já avaliados por $user$
- 2: $scores \leftarrow$ dicionário vazio
- 3: **for all** $p_1 \in vizinhos(user)$ **do**
- 4: **if** p_1 não é produto **then continue**
- 5: **end if**
- 6: $w_1 \leftarrow 1/\text{grau}(p_1)$
- 7: **for all** $u_2 \in vizinhos(p_1)$ **do**
- 8: **if** $u_2 = user$ **then continue**
- 9: **end if**
- 10: $w_2 \leftarrow w_1/\text{grau}(u_2)$
- 11: **for all** $p_2 \in vizinhos(u_2)$ **do**
- 12: **if** p_2 não é produto **ou** $p_2 \in seen$ **then continue**
- 13: **end if**
- 14: $scores[p_2] += w_2$
- 15: **end for**
- 16: **end for**
- 17: **end for**
- 18: **return** top- $K(scores)$

Algorithm 2: Multi-Hop com Penalização


Require: grafo G , usuário $user$, função $\text{pen}(\cdot)$, conjunto K
Ensure: lista dos K produtos com maior $score$

- 1: $seen \leftarrow$ produtos já avaliados por $user$
- 2: $scores \leftarrow$ dicionário vazio
- 3: **for all** $p_1 \in vizinhos(user)$ **do**
- 4: **if** p_1 não é produto **then continue**
- 5: **end if**
- 6: $w_1 \leftarrow \text{pen}(\text{grau}(p_1))$
- 7: **for all** $u_2 \in vizinhos(p_1)$ **do**
- 8: **if** $u_2 = user$ **then continue**
- 9: **end if**
- 10: $w_2 \leftarrow w_1 \cdot \text{pen}(\text{grau}(u_2))$
- 11: **for all** $p_2 \in vizinhos(u_2)$ **do**
- 12: **if** p_2 não é produto **ou** $p_2 \in seen$ **then continue**
- 13: **end if**
- 14: $scores[p_2] += w_2$
- 15: **end for**
- 16: **end for**
- 17: **end for**
- 18: **return** top- $K(scores)$


Algorithm 3 Personalized PageRank em Lote

Require: grafo G , conjunto de usuários U , fator α , limiar $\varepsilon = 10^{-6}$
Ensure: $\text{cache_ppr}[u]$ para cada $u \in U$

- 1: $A_{\text{norm}} \leftarrow$ matriz esparsa normalizada por coluna a partir de G
- 2: **for all** bloco $B \subseteq U$ com $|B| \leq 100$ **do**
- 3: $P \leftarrow$ matriz de zeros de dimensão $|V| \times |B|$
- 4: **for all** $u \in B$ **do**
- 5: $P[\text{idx}(u), \text{pos}(u, B)] \leftarrow 1,0$
- 6: **end for**
- 7: $scores \leftarrow P$
- 8: **repeat**
- 9: $scores \leftarrow \alpha \times A_{\text{norm}} \cdot scores + (1 - \alpha) \times P$
- 10: **until** convergência ou 100 iterações
- 11: **for all** $u \in B$ **do**
- 12: $\text{cache_ppr}[u] \leftarrow scores[:, \text{pos}(u, B)]$
- 13: **end for**
- 14: **end for**



(a) Precision@10 por modelo e período de avaliação, nos modos *all* (esquerda) e *rated* (direita).



(b) *Trade-off* entre Precision@10 e diversidade médias sobre os seis cenários avaliados.

Figura 4.1: Comparação dos resultados obtidos pelos modelos avaliados.

Links

Os principais artefatos produzidos durante o desenvolvimento deste projeto encontram-se disponíveis nos endereços a seguir.

Código-fonte do projeto

<https://github.com/lucas-guarnieri/mc859-project>

Grafos gerados e artefatos experimentais

Release no GitHub: <https://github.com/lucas-guarnieri/mc859-project/releases/tag/graphs-v2>

Espelho contendo os arquivos completos: https://drive.google.com/drive/folders/10dyR_Y3LfG_0y1mzkjpWywaz1kgwQGzp?usp=sharing

Referências

- [1] Jonathan L. Herlocker et al. “Evaluating Collaborative Filtering Recommender Systems”. Em: *ACM Transactions on Information Systems* (2004). DOI: 10.1145/963770.963772. URL: <https://dl.acm.org/doi/10.1145/963770.963772>.
- [2] Kalervo Järvelin e Jaana Kekäläinen. “Cumulated Gain-Based Evaluation of IR Techniques”. Em: *ACM Transactions on Information Systems* 20.4 (2002), pp. 422–446. DOI: 10.1145/582415.582418. URL: <https://dl.acm.org/doi/10.1145/582415.582418>.
- [3] Glen Jeh e Jennifer Widom. “Scaling Personalized Web Search”. Em: *Proceedings of the 12th International Conference on World Wide Web (WWW '03)*. 2003, pp. 271–279. DOI: 10.1145/775152.775191. URL: <https://dl.acm.org/doi/10.1145/775152.775191>.
- [4] Julian McAuley. *Amazon Review Data (2018)*. https://cseweb.ucsd.edu/~jmcauley/datasets/amazon_v2/. Acessado em abril de 2026. 2018.
- [5] Tao Zhou et al. “Bipartite network projection and personal recommendation”. Em: *Phys. Rev. E* 76 (4 2007). DOI: 10.1103/PhysRevE.76.046115. URL: <https://link.aps.org/doi/10.1103/PhysRevE.76.046115>.

Nota: O desenvolvimento deste projeto contou com o auxílio do assistente de inteligência artificial Claude (Anthropic), utilizado como apoio na geração e revisão de trechos de código Python e na revisão de partes do texto deste relatório. O conteúdo técnico, as decisões de projeto e as análises são de responsabilidade do autor.