

Proposta de Projeto

Análise e Mitigação da Centralização de Caminhos em Sistemas de Recomendação Baseados em Grafos Temporais

Introdução

Em plataformas digitais a sugestão de novos produtos e conteúdos para usuários é uma prática já bem consolidada. As recomendações são inferidas com base em comportamentos do usuário, como visualização, compra e avaliação de produtos. Para extrair dados que gerem recomendações relevantes, uma estratégia bastante utilizada é a representação das interações dos usuários com produtos por meio de grafos, onde usuários e produtos são modelados como nós e suas interações como arestas.

Essa representação permite explorar não apenas relações diretas, mas também relações indiretas (multi-hop). Por exemplo, um sistema pode recomendar um produto com base em outros itens comprados por usuários semelhantes ou pertencentes à mesma categoria. Esse tipo de inferência amplia a capacidade do sistema de capturar padrões complexos e gerar recomendações mais informadas.

Entretanto, ao longo do tempo, produtos muito populares tornam-se nós altamente conectados no grafo, concentrando grande parte dos caminhos utilizados para a geração de recomendações. Isso pode fazer com que algoritmos passem a favorecer repetidamente itens ou categorias, prejudicando a qualidade e diversidade das recomendações.

Esse fenômeno pode ser interpretado como uma centralização de caminhos (path centralization), na qual a diversidade estrutural dos caminhos utilizados pelo sistema diminui ao longo do tempo. Esse comportamento está relacionado ao viés de popularidade, mas se manifesta de forma mais complexa em sistemas baseados em grafos multi-hop, pois afeta não apenas itens individuais, mas também os próprios caminhos de inferência.

Objetivos

O objetivo geral deste projeto é analisar a evolução da centralização de caminhos em sistemas de recomendação baseados em grafos ao longo do tempo, investigando como a concentração de nós intermediários nos processos de inferência afeta a qualidade das recomendações. Para isso, será conduzido um estudo experimental comparativo entre diferentes algoritmos de recomendação, incluindo métodos baseados em grafos e abordagens clássicas, avaliando tanto métricas tradicionais de desempenho quanto métricas estruturais propostas.

Adicionalmente, o projeto busca avaliar a eficácia de estratégias de mitigação, por meio da penalização de nós altamente conectados, na redução da centralização e seus possíveis impactos sobre a precisão das recomendações.

Metodologia

O projeto será conduzido como um estudo experimental comparativo, estruturado em quatro etapas principais: preparação dos dados, construção do grafo, implementação dos métodos de recomendação e análise dos resultados ao longo do tempo.

Na etapa de preparação dos dados, será utilizado o Amazon Reviews Dataset, amplamente empregado em estudos de sistemas de recomendação, por conter avaliações de produtos acompanhadas de timestamps. Inicialmente, será realizada uma etapa de pré-processamento, incluindo limpeza dos dados, remoção de usuários e itens com baixa atividade e organização cronológica das interações. A fim de possibilitar a análise temporal, os dados serão particionados em snapshots anuais, nos quais cada snapshot contém todas as interações acumuladas até o final de um determinado ano.

Na etapa de construção do grafo, as interações serão representadas por um grafo heterogêneo contendo nós do tipo usuário, produto e categoria. As arestas representarão relações do tipo usuário-avaliou-produto, sendo as avaliações utilizadas como proxy de consumo, além de relações produto-pertence-à-categoria. Cada aresta estará associada a um timestamp, permitindo a construção incremental do grafo ao longo dos anos considerados.

Na etapa de implementação dos métodos, serão considerados cinco algoritmos de recomendação, escolhidos de forma a abranger diferentes abordagens. Serão implementados métodos baseados em popularidade global, coocorrência de itens e filtragem colaborativa baseada em itens, além de um método baseado em random walk, como o Personalized PageRank [2]. Também será implementado um modelo de recomendação baseado na exploração de caminhos multi-hop no grafo, conforme abordagens discutidas na literatura [4].

Adicionalmente, será proposta uma variação do modelo multi-hop que incorpora um mecanismo de penalização de nós altamente conectados. Nesse modelo, o peso de um caminho será reduzido em função do grau dos nós intermediários, de forma a limitar a influência de hubs e reduzir a concentração estrutural dos caminhos utilizados na geração de recomendações.

A avaliação será conduzida de forma temporal. Para cada ano t , o grafo será construído utilizando apenas interações observadas até esse ano, e os algoritmos serão avaliados na tarefa de prever interações que ocorrem no ano seguinte. Esse procedimento simula um cenário realista de recomendação, evitando o uso de informação futura.

Os algoritmos serão comparados com base em métricas tradicionais da área, como Precision@K e NDCG@K [1, 3], que avaliam a qualidade do ranking gerado. Além disso, será proposta uma métrica composta para avaliar a diversidade das recomendações, combinando aspectos de dispersão dos itens recomendados e penalização de concentração em itens populares. Essa métrica permitirá analisar o trade-off entre relevância e diversidade.

Adicionalmente, será analisada a centralização estrutural dos caminhos utilizados pelos métodos baseados em grafo, por meio de métricas como entropia e índice de Gini aplicadas à distribuição de frequência dos nós intermediários nos caminhos de recomendação.

Por fim, os resultados serão analisados ao longo dos diferentes anos, permitindo observar a evolução tanto da qualidade das recomendações quanto da centralização estrutural. Será investigado, em particular, o impacto da penalização de nós centrais no equilíbrio entre desempenho e diversidade das recomendações.

Planejamento

O projeto será desenvolvido em quatro fases ao longo de 12 semanas.

Na primeira fase (semanas 1–3), será realizado o estudo do problema, revisão bibliográfica e preparação dos dados. Nessa fase será também analisada a viabilidade da utilização do dataset Amazon Reviews, com possibilidade da adoção de um subconjunto do dataset como contingência. Na segunda fase (semanas 4–5), será feita a modelagem e construção do grafo temporal. Na terceira fase (semanas 6–9), serão implementados os métodos baseline, o modelo multi-hop e o mecanismo de penalização. Por fim, na quarta fase (semanas 10–12), serão conduzidos os experimentos, análise dos resultados e elaboração do relatório final.

References

- [1] Kalervo Järvelin and Jaana Kekäläinen. Cumulated gain-based evaluation of ir techniques. *ACM Transactions on Information Systems*, 20(4):422–446, 2002.
- [2] Lawrence Page, Sergey Brin, Rajeev Motwani, and Terry Winograd. The pagerank citation ranking: Bringing order to the web. *Stanford InfoLab*, 1999.
- [3] Francesco Ricci, Lior Rokach, and Bracha Shapira. *Recommender Systems Handbook*. Springer, 2011.
- [4] Yue Shi, Martha Larson, and Alan Hanjalic. Collaborative filtering beyond the user-item matrix: A survey of the state of the art and future challenges. *ACM Computing Surveys*, 47(1), 2014.